

شرح Phase 2 بالتفصيل

Text-to-Video Generation using Diffusion Models

شرح مصري مفصل للتحسينات، التجارب، النتائج، والبونص

المشروع	Short Movie Clip Generation
المرحلة	Phase 2 - Enhancement & Final Paper
الموضوع	Human Motion in Dynamic Environments
النسخة النهائية المختارة	Enhancement B - Temporal Stabilization

شرح Phase 2 بالتفصيل - Text-to-Video Generation using Diffusion Models

1. فكرة Phase 2 باختصار

في Phase 1 كنا عاملين pipeline أساسي لتوليد فيديو من نص. الـ pipeline كانت ماشية على مرحلتين:

1. Text-to-Image

بنستخدم Stable Diffusion XL عشان نحول الـ prompt لصورة أولى.

1. Image-to-Video

بنستخدم Stable Video Diffusion عشان نحول الصورة دي لسلسلة frames وتطلع فيديو قصير.

في Phase 1 عملنا كمان تقييم للنتائج باستخدام مقياس زي:

- **CLIP-SIM** عشان نقيس هل الفيديو مطابق للـ prompt ولا لأ.
 - **SSIM** عشان نقيس التشابه بين كل frame واللي بعدها، وده مؤشر على temporal consistency.
 - **Mean Frame Difference** عشان نقيس قد إيه فيه تغير شديد بين الفريمات.
 - **LPIPS Temporal** في Phase 2 عشان نقيس اختلاف perceptual بين الفريمات، وكل ما يقل يبقى أفضل من ناحية flickering.
- من نتائج Phase 1 لقينا إن المشكلة الأساسية مش في إن الفيديو بي فهم الـ prompt. بالعكس، الـ CLIP-SIM كان كويس. المشكلة الأكبر كانت في:

- flickering
- عدم ثبات شكل الأشخاص والعريبات
- motion مش طبيعي أحياناً
- temporal consistency متوسطة أو ضعيفة خصوصاً في المشاهد المعقدة

عشان كده Phase 2 ركزت على تحسين نقطتين:

1. تحسين فهم الـ prompt وتقليل artifacts.
2. تحسين الثبات الزمني وتقليل الفليكر.

2. متطلبات Phase 2 حسب ملف المشروع

Phase 2 كانت طالبة الحاجات دي:

1. Fully implemented enhancements

يعني نعمل تحسينات حقيقية على النظام، مش مجرد كلام.

1. Mathematical motivation

يعني نشرح ليه التحسين منطقي رياضياً أو من ناحية آلية عمل diffusion models.

1. Ablation study

لازم نقارن:

- baseline
- enhancement A
- enhancement B
- combined A+B

1. Final generated video ≥ 4 seconds

الفديو النهائي لازم يكون 4 ثواني أو أكثر.

1. Final paper

لازم الورقة العلمية تتحدث وتحتوي على نتائج Phase 2.

1. Clean code repository

لازم يكون فيه notebook/code و requirements و generation script.

1. Bonus optional

Text-to-Audio لو عايزين نزود درجة المشروع.

3. إحنا عملنا إيه في Phase 2؟

عملنا Phase 2 كـ ablation study منظم على أربع نسخ:

1. Baseline

ده نفس أسلوب Phase 1 تقريبًا.

1. Enhancement A - Prompt and CFG Enhancement

تحسين semantic alignment باستخدام أقوى prompt و negative prompt و guidance scale أعلى.

1. Enhancement B - Temporal Enhancement

تحسين temporal consistency باستخدام motion/noise parameters أقل، temporal smoothing، و frame interpolation.

1. Combined A+B

نسخة تجمع التحسينين مع بعض.

الفكرة هنا إننا مش بس نقول "عملنا تحسين"، لكن نثبت بالأرقام تأثير كل تحسين لوحده، وتأثير الجمع بينهم.

4. الـ Baseline كان إيه؟

الـ baseline هو أقرب نسخة لكود Phase 1:

- SDXL بيولد initial image من الـ prompt.
- SVD بيحول الصورة لفيديو.

- FPS = 7
- عدد الفريمات = 25
- مدة الفيديو = 3.57 ثانية تقريبًا
- guidance scale = 7.5
- motion bucket id = 127
- noise augmentation strength = 0.10

ال prompt الأساسي كان:

A person walking in a busy street with moving cars and background elements,
daytime, dynamic motion, cinematic tracking shot

ال baseline مهم جدًا لأنه هو نقطة المقارنة. أي enhancement لازم نقارنه بيه.

5. Enhancement A - تحسين ال Prompt وال CFG

5.1 الهدف من Enhancement A

الهدف من Enhancement A كان تحسين semantic alignment وتقليل artifacts اللي بتحصل بسبب prompt عام زيادة.

في Phase 1، ال prompt كان بيوصف المشهد، لكنه ماكانش بيحبر الموديل على حاجات مهمة زي:

- ثبات شكل الشخص
- ثبات الملابس
- حركة مشي طبيعية
- كاميرا مستقرة
- تقليل التشوهات
- تقليل flickering

عشان كده زدنا ال prompt وخذناه من وصف عام لوصف أدق.

5.2 ال Enhanced Prompt

بدل ال prompt الأصلي فقط، استخدمنا prompt أطول:

A person walking in a busy street with moving cars and background elements,
daytime, dynamic motion, cinematic tracking shot,
coherent human anatomy, consistent face and clothes across frames,
natural walking gait, stable camera motion, realistic shadows,
detailed urban environment

الفكرة إننا بندي الموديل قيود semantic أوضح:

- coherent human anatomy

عشان يقلل تشوه جسم الإنسان.

• consistent face and clothes across frames

عشان نحاول نحافظ على نفس الشخص والملابس بين الفريمات.

• natural walking gait

عشان الحركة تبقى أقرب للمشي الطبيعي.

• stable camera motion

عشان الكاميرا ما تبقاش مهزوزة بشكل مبالغ.

5.3 الـ Negative Prompt

كمان استخدمنا negative prompt:

```
flicker, jitter, distorted body, deformed hands, extra limbs,
duplicate person, warped face, unstable background, text,
watermark, low quality, blurry
```

الـ negative prompt بيقول للموديل يتجنب إيه. وده مهم لأن video diffusion ممكن يطلع:

- أطراف زيادة
- وشوش مشوهة
- أشخاص بيتغيروا من frame للثاني
- خلفية غير ثابتة
- blur أو low quality

5.4 تعديل Classifier-Free Guidance

في Enhancement A رفعنا guidance scale من:

7.5

إلى:

10.0

الفكرة رياضياً إن Classifier-Free Guidance بيقوي تأثير النص على عملية denoising.

المعادلة المستخدمة:

```
epsilon_hat =
epsilon_uncond + w * (epsilon_cond - epsilon_uncond)
```

أو بشكل أوضح:

• `epsilon_uncond` : توقع الموديل بدون prompt.

- `epsilon_cond`: توقع الموديل باستخدام `prompt`.
- `w`: `guidance scale`.

لما نزود `w` ، الموديل يميل أكثر إنه يتبع النص. بس لو زودناه زيادة عن اللزوم ممكن تظهر `artifacts` أو يقل التنوع.

5.5 نتيجة Enhancement A

Enhancement A حسّن `temporal metrics` شوية:

- Mean SSIM زاد من 0.7049 إلى 0.8064.
- Mean Frame Difference قل من 19.9993 إلى 10.1719.

لكن CLIP-SIM قل بسيط:

- من 34.2195 إلى 33.8013.

وده معناه إن `prompt conditioning` ساعد في الثبات نسيئاً، لكنه ماكناش أفضل نسخة إجمالاً.

6 Enhancement B - Temporal Stabilization

6.1 الهدف من Enhancement B

Enhancement B هو أهم تحسين في Phase 2.

هدفه الأساسي:

- تقليل flickering
- تحسين temporal consistency
- جعل الفيديو أطول من 4 ثواني
- تخفيف الحركة العنيفة اللي بتسبب تشوهات

6.2 تعديل SVD Parameters

في الـ baseline كانت القيم:

```
motion_bucket_id = 127
noise_aug_strength = 0.10
fps = 7
```

في Enhancement B استخدمنا:

```
motion_bucket_id = 80
noise_aug_strength = 0.04
fps = 12
```

6.3 معنى motion_bucket_id

`motion_bucket_id` بيتحكم في شدة الحركة اللي Stable Video Diffusion بيحاول يولدها.

لو القيمة عالية:

- الحركة بتبقى أقوى.
- ممكن الفيديو يبقى dynamic أكثر.
- لكن ممكن كمان يزيد التشوه والفليكر.

لو القيمة أقل:

- الحركة بتبقى أهدى.
- الثبات بين الفريمات يتحسن.
- لكن الحركة ممكن تبقى أقل درامية.

إحنا اخترنا 80 بدل 127 عشان نقلل الحركة المبالغ فيها ونحافظ على ثبات المشهد.

6.4 معنى noise_aug_strength

noise_aug_strength بيتحكم في كمية noise اللي بتضاف للصورة الأولية قبل تحويلها لفيديو.

لو noise عالي:

- الموديل عنده حرية أكبر يغير المشهد.
- ممكن يطلع motion أقوى.
- لكن ممكن يغير تفاصيل مهمة بين الفريمات.

لو noise أقل:

- الموديل يتمسك أكثر بالصورة الأصلية.
- التفاصيل تبقى أكثر ثباتًا.
- الفليكر يقل.

عشان كده قللناه من 0.10 إلى 0.04.

Temporal Smoothing 6.5

بعد توليد الفريمات، طبقنا temporal smoothing.

الفكرة إن كل frame جديد بيتخلط بنسبة بسيطة مع frame قبله، عشان التغييرات المفاجئة تقل.

المعادلة:

$$I_smooth[t] = \alpha * I[t] + (1 - \alpha) * I_smooth[t-1]$$

حيث:

- $I[t]$: الفريم الأصلي عند الزمن t .
- $I_smooth[t]$: الفريم بعد التنعيم.
- α : نسبة الاحتفاظ بالفريم الحالي.

في الكود استخدمنا:

```
alpha = 0.82
```

ده معناه:

- 82% من الفريم الحالي.
 - 18% من الفريم السابق بعد smoothing.
- النسبة دي بتقلل الفليكر من غير ما تمسح الحركة تمامًا.

Frame Interpolation 6.6

كمان استخدمنا frame interpolation.

الفيديو الأصلي من SVD بيطلع 25 frame. لو $\text{fps} = 7$ ، المدة:

```
25 / 7 = 3.57 seconds
```

وده أقل من شرط Phase 2 اللي طالب فيديو 4 ثواني أو أكثر.

عشان كده ضفنا frames وسطية بين الفريمات باستخدام linear interpolation.

بعد interpolation بقى عندنا 49 frame، ومع $\text{fps} = 12$:

```
49 / 12 = 4.08 seconds
```

وده بيحقق الشرط.

6.7 interpolation مش مجرد تطويل؟

هو فعلاً بيطول الفيديو، لكنه كمان بيخلي الانتقال بين الفريمات أنعم، لأننا بنضيف frame وسطي بين كل frame واللي بعده.

الفريم الوسطي بيتحسب كده:

```
middle_frame = (1 - w) * frame_1 + w * frame_2
```

وده بيقلل jump المفاجئ بين الفريمات.

6.8 نتيجة Enhancement B

Enhancement B كان أفضل نسخة إجمالاً:

- CLIP-SIM زاد من 34.2195 إلى 34.9508.
- Mean SSIM زاد من 0.7049 إلى 0.9567.
- Mean Frame Difference قل من 19.9993 إلى 4.4957.
- LPIPS Temporal قل إلى 0.0438.
- مدة الفيديو بقت 4.08 ثانية.
- Temporal consistency بقت good.

- Semantic alignment فضل good.

عشان كده اخترناه كـ final video.

7. Combined A+B

7.1 الفكرة

الـ Combined A+B بيجمع:

- prompt conditioning و negative prompt و CFG من Enhancement A.

- temporal stabilization و interpolation من Enhancement B.

يعني المفروض يجمع بين semantic alignment والثبات الزمني.

7.2 النتيجة

الـ Combined A+B طلع كويس جدًا:

- Mean SSIM = 0.9466

- Mean Frame Difference = 3.9539

- Mean PSNR = 28.4856

- Duration = 4.08 seconds

لكن CLIP-SIM كان أقل من Enhancement B:

Combined A+B CLIP-SIM = 33.6461

Enhancement B CLIP-SIM = 34.9508

عشان كده، رغم إن Combined A+B عنده frame difference أقل و PSNR أعلى، اخترنا Enhancement B كـ final لأنه أفضل توازن عام بين:

- semantic alignment

- temporal consistency

- مدة الفيديو

- LPIPS temporal

8. جدول نتائج Phase 2

Variant	CLIP-SIM	Mean SSIM	Mean PSNR	Mean Frame Diff	LPIPS Temporal	Duration	Temporal	Semantic
Baseline	34.2195	0.7049	16.4532	19.9993	0.2033	3.57s	Moderate	Good
Enhancement A	33.8013	0.8064	20.0771	10.1719	0.0967	3.57s	Moderate	Good
Enhancement B	34.9508	0.9567	27.9292	4.4957	0.0438	4.08s	Good	Good
Combined A+B	33.6461	0.9466	28.4856	3.9539	0.0445	4.08s	Good	Good

9. تفسير الأرقام

CLIP-SIM 9.1

CLIP-SIM يقيس مدى توافق الفيديو مع النص.

أعلى نتيجة كانت:

Enhancement B = 34.9508

وده معناه إن تقليل الحركة والـ noise ما أضعفش فهم المشهد. بالعكس، خلى الفيديو أوضح وأكثر استقرارًا، وده ساعد CLIP يشوف إن الفيديو مطابق للنص.

Mean SSIM 9.2

SSIM يقيس تشابه الفريمات المتتالية.

الـ baseline:

0.7049

Enhancement B:

0.9567

ده تحسن كبير جدًا، معناه إن الفريمات بقت أكثر ثباتًا.

Mean Frame Difference 9.3

ده يقيس متوسط فرق البكسلات بين الفريمات.

الـ baseline:

19.9993

Enhancement B:

4.4957

فرق كبير جدًا. معناه إن الفليكر والتغير المفاجئ قلوا.

LPIPS Temporal 9.4

LPIPS يقيس اختلاف perceptual مش مجرد اختلاف pixels.

الـ baseline:

0.2033

Enhancement B:

0.0438

كل ما الرقم يقل، يبقى الفريمات أقرب perceptually، وده معناه flickering أقل.

Duration 9.5

الـ baseline و Enhancement A مدتهما:

3.57 seconds

وده أقل من المطلوب.

Enhancement B و Combined A+B:

4.08 seconds

وده بيحقق شرط Phase 2.

10. ليه اخترنا Enhancement B ؟ Final Video

اخترنا Enhancement B لأنه أفضل نسخة بشكل عام.

الأسباب:

1. أعلى CLIP-SIM.

2. أعلى Mean SSIM.

3. أقل LPIPS Temporal.

4. مدة الفيديو 4.08 ثانية.

5. temporal consistency = good.

6. semantic alignment = good.

7. يبحل المشكلة الأساسية التي ظهرت في Phase 1 وهي الفليكر وعدم الثبات الزمني.

الفيديو النهائي إذن هو:

enhancement_B_temporal/output_video.mp4

ولو عليه صوت البونص:

final_video_with_neural_tts.mp4

11. التغيير بين Phase 1 و Phase 2

Phase 1 11.1

Phase 1 كانت تحليلية أكثر:

- بنولد فيديوهات.
- بنغير guidance scale.
- بنغير inference steps.
- بنقارن simple / medium / complex.
- بنطلع metrics.
- بنحدد نقاط الضعف.

Phase 2 11.2

Phase 2 كانت تحسين وتنفيذ:

- حددنا المشكلة الأساسية: temporal inconsistency.
- عملنا Enhancement A للـ prompt والـ CFG.
- عملنا Enhancement B للـ temporal stabilization.
- عملنا combined version.
- عملنا ablation study كامل.
- اخترنا final video.
- زودنا bonus text-to-audio.

12. شرح الكود الخاص بـ Phase 2

12.1 إعداد الـ variants

في النوتبوك عرفنا dictionary اسمها `VARIANTS`.

جواها الأربع نسخ:

```
VARIANTS = {
    "baseline": {...},
    "enhancement_A_prompt_cfg": {...},
    "enhancement_B_temporal": {...},
    "combined_A_B": {...},
}
```

كل variant فيها:

- prompt
- negative prompt
- guidance scale
- motion bucket id
- noise augmentation strength
- هل نطبق temporal smoothing ولا لا
- هل نطبق interpolation ولا لا
- fps

12.2 دالة توليد الفيديو

الدالة الأساسية:

```
generate_variant(...)
```

بتعمل الآتي:

1. تولد صورة باستخدام SDXL.
2. تحفظ الصورة باسم `initial_image.png`.
3. تحول الصورة لفيديو باستخدام SVD.
4. تطبق temporal smoothing لو مطلوب.
5. تطبق interpolation لو مطلوب.
6. تحفظ الفريمات.
7. تحفظ الفيديو.
8. تحسب metrics.
9. تحفظ metadata.

12.3 دالة temporal smoothing

الدالة:

```
temporal_smooth_frames(frames, alpha=0.82)
```

بتعدي على كل frame وتخلطه بجزء من الفريم السابق.

ده بيقلل التغيرات المفاجئة.

12.4 دالة interpolation

الدالة:

```
interpolate_frames_linear(frames, factor=2)
```

بتضيف frame وسطي بين كل frame واللي بعدها.

ده بيعمل حاجتين:

- يخلي الحركة أنعم.
- يزود عدد الفريمات وبالتالي مدة الفيديو.

12.5 دوال التقييم

استخدمنا:

- `calculate_temporal_metrics`
- `calculate_clip_sim`
- `calculate_optional_lpips`
- `analyze_metrics`

كل دول بيطلعوا metrics ويتحولوا للتقييم:

- good
- moderate
- poor

13. مخرجات Phase 2

المخرجات المهمة:

```
phase2_ablation_summary.json
phase2_ablation_table.csv
phase2_ablation_metrics.png
phase2_paper_notes.md
repository_files/requirements.txt
repository_files/generate_phase2_video.py
```

ولكل variant:

```
initial_image.png
output_video.mp4
metadata.json
frames/
```

14. البونص - Text-to-Audio

14.1 فكرة البونص

البونص في ملف المشروع كان Text-to-Audio.

المطلوب إنه مايقاش مجرد TTS بسيط، لكن يكون فيه advanced features زي:

- neural TTS
- multi-voice
- emotion/style control
- speed/pitch control
- context-aware pauses
- integration مع الفيديو

إحنا عملنا ده باستخدام:

SpeechT5

وده neural text-to-speech model من HuggingFace.

14.2 الهدف من البونص

الفكرة إن الفيديو النهائي مايقاش silent فقط، لكن يكون عليه narration قصير يشرح المشهد أو التحسين.

مثال النص:

Smooth city walking. Temporal smoothing reduces flicker.

النص قصير عمدًا لأن الفيديو حوالي 4 ثواني فقط.

لو النص طويل، الصوت هيبقى سريع أو يتقص، ويمكن يبقى مش مفهوم.

15. مكونات البونص

Neural TTS Model 15.1

استخدمنا:

```
microsoft/speecht5_tts
```

ومعه vocoder:

```
microsoft/speecht5_hifigan
```

الـ TTS model يحول النص لتمثيل صوتي، والـ HiFi-GAN vocoder يحول التمثيل ده لموجة صوتية waveform.

Speaker Embeddings 15.2

عشان نعمل multi-voice، استخدمنا speaker embeddings من dataset:

```
Matthijs/cmu-arctic-xvectors
```

كل speaker embedding بيدي شخصية صوت مختلفة.

في الكود عرفنا:

```
VOICE_PRESETS = {
    "voice_1": 7306,
    "voice_2": 2272,
    "voice_3": 5725,
}
```

يعني عندنا 3 voices مختلفة.

Style / Emotion Controls 15.3

عملنا styles:

```
STYLE_PRESETS = {
    "neutral": {...},
    "happy": {...},
    "calm": {...},
    "clear": {...},
}
```

كل style بيتحكم في:

- speed
- pitch

- pause after comma
- pause after period

15.4 شرح كل style

neutral

ده صوت طبيعي ومتوازن.

```
speed = 1.15
pitch_steps = 0
```

happy

ده أسرع شوية و pitch أعلى.

```
speed = 1.25
pitch_steps = 2
```

بيحاول يدي إحساس أكثر نشاطاً.

calm

ده أبطأ شوية و pitch أقل.

```
speed = 0.95
pitch_steps = -1
```

بيحاول يدي إحساس أهدى.

clear

ده أضفناه عشان يبقى أوضح في العرض.

```
speed = 1.0
pitch_steps = 0
```

وده غالباً أفضل نسخة لو الدكتور عايز يسمع الكلام بوضوح.

16. Context-Aware Pauses

عملنا function بتقسم النص حسب علامات الترقيم:

- comma
- period
- question mark
- exclamation mark

لو الجملة انتهت بـ period، بنضيف pause أطول.

لو فيها comma، بنضيف pause أقصر.

ده اسمه context-aware synthesis لأن الصوت مش بيطلع كلمة ورا كلمة بدون إحساس، لكن بيحاول يحترم بنية الجملة.

مثال:

Smooth city walking. Temporal smoothing reduces flicker.

هنا فيه جملتين، فبينهم pause مناسب.

17. دمج الصوت مع الفيديو

بعد ما بنولد ملف الصوت:

phase2_neural_narration.wav

بنستخدم FFmpeg عشان ندمجه مع final video:

final_video_with_neural_tts.mp4

الأمر في الكود بيعمل:

- يأخذ video stream من الفيديو النهائي.
- يأخذ audio stream من ملف WAV.
- يطلع MP4 فيه فيديو وصوت.
- يستخدم `-shortest` عشان لو الصوت أطول من الفيديو، يقف عند نهاية الأقصر.

18. توليد فيديو بكل Voice وكل Style

عشان نعرض البونص للدكتور بشكل واضح، عملنا batch generation.

يعني نفس الفيديو النهائي بيتكرر مع كل voice وكل style.

عندنا:

- voices 3
- styles 4

إذن:

3 * 4 = 12 videos

كل فيديو اسمه بالشكل ده:

```
final_video_voice_1_neutral.mp4
final_video_voice_1_happy.mp4
final_video_voice_1_calm.mp4
final_video_voice_1_clear.mp4
...
```

وده مهم جدًا في العرض، لأنه يثبت إن البونص مش مجرد ملف صوت واحد، لكن module كامل فيه:

- multi-voice
- emotion/style control
- audio-video integration

19. مخرجات البونص

المخرجات المهمة للبونص:

```
bonus_text_to_audio/phase2_neural_narration.wav
bonus_text_to_audio/final_video_with_neural_tts.mp4
bonus_text_to_audio/bonus_audio_metadata.json
bonus_text_to_audio/bonus_text_to_audio_notes.md
bonus_text_to_audio/all_voice_style_videos/
bonus_text_to_audio/all_voice_style_videos.zip
```

ملف الـ zip يحتوي على كل نسخ الفيديو بالصوت لكل voice/style.

20. مشكلة الصوت غير الواضح وحلها

في بعض التجارب، صوت SpeechT5 ممكن يطلع غير واضح، خصوصًا لو:

- النص طويل.
- السرعة عالية.
- pitch متغير زياده.
- الفيديو قصير.

عشان كده عملنا style اسمه:

```
clear
```

واستخدمنا نص قصير:

```
Smooth city walking. Temporal smoothing reduces flicker.
```

ده بيخلي الصوت أوضح وأسهل للفهم.

لو الصوت لسه مش واضح، نختار voice ثانية:

voice_2
voice_3

ونقارن بينهم.

21. إزاي نشرح Phase 2 للدكتور

ممکن تقول:

في Phase 1، عملنا baseline pipeline بيحول النص لصورة باستخدام SDXL وبعدها يحول الصورة لفيديو باستخدام Stable Video Diffusion. بعد التقييم، لقينا إن semantic alignment جيد، لكن temporal consistency كانت المشكلة الأكبر بسبب flickering وتغير شكل الأجسام بين الفريمات.

في Phase 2، عملنا enhancement A لتحسين الـ prompt والـ classifier-free guidance، و enhancement B لتحسين الثبات الزمني باستخدام motion/noise parameters أقل، و temporal smoothing، و frame interpolation.

بعد كده عملنا ablation study بين baseline و A و B و A+B. النتائج أظهرت إن Enhancement B هو الأفضل، لأنه رفع Mean SSIM من 0.7049 إلى 0.9567 وقلل frame difference من 19.9993 إلى 4.4957، وكمان حقق مدة 4.08 ثانية، فاخترناه كـ final video.

وبالنسبة لليونس، ضفنا neural text-to-audio module باستخدام SpeechT5. الموديول بيولد narration من النص، بيدعم كذا voice وكذا style، ويبضيف pauses حسب علامات الترقيم، وبعدها بنركب الصوت على الفيديو النهائي باستخدام FFmpeg.

22. إزاي نشرح اختيار Enhancement B

ممکن تقول:

اخترنا Enhancement B لأنه بيعالج المشكلة الأساسية اللي ظهرت في Phase 1 وهي temporal instability. بدل ما نركز بس على تحسين النص، قللنا شدة الحركة والـ noise داخل SVD، وبعدها طبقنا temporal smoothing و interpolation. ده خلى الفريمات أكثر ثباتًا، وقلل الفليكر، وزود مدة الفيديو لأكثر من 4 ثواني.

بالأرقام:

Mean SSIM:
Baseline = 0.7049
Enhancement B = 0.9567

Mean Frame Difference:
Baseline = 19.9993
Enhancement B = 4.4957

LPIPS Temporal:
Baseline = 0.2033
Enhancement B = 0.0438

ده دليل إن التحسين الزمني اشتغل بوضوح.

23. إزاي نشرح البونص للدكتور

ممکن تقول:

عملنا optional Text-to-Audio bonus. استخدمنا SpeechT5 كـ neural TTS model بدل TTS بسيط. الموديول بياخد short narration text ويولده كصوت، وبعدين بتركبه على الفيديو النهائي.

الموديول فيه:

- 3 voices مختلفة باستخدام speaker embeddings.
- 4 styles: neutral, happy, calm, clear.
- تحكم في speed و pitch.
- pauses مبنية على punctuation.
- إخراج فيديوهات متعددة، كل فيديو بنفس المشهد لكن بصوت أو style مختلف.

وده بيحقق متطلبات البونص لأنه مش مجرد speech synthesis بسيط، لكنه multimodal extension ببيضيف audio storytelling للفيديو.

24. حدود التحسينات

رغم إن النتائج اتحسننت، لسه فيه حدود:

1. Temporal smoothing ممكن يقلل الحركة لو زاد زيادة عن اللزوم.
2. Interpolation بيحسن النعومة، لكنه مش بيخلق motion حقيقي جديد زي optical flow المتقدم.
3. SVD نفسه محدود في المشاهد المزدحمة جدًا.
4. SpeechT5 أحياناً صوته مش واضح مع النصوص الطويلة.
5. الفيديوهات القصيرة بتجبرنا نخلي narration قصير جدًا.

25. الخلاصة النهائية

Phase 2 حسنت Phase 1 بشكل واضح.

في Phase 1 كان عندنا pipeline شغال ونتائج semantic كويسة، لكن temporal consistency كانت متوسطة.

في Phase 2 عملنا:

- Enhancement A للـ prompt والـ CFG.
- Enhancement B للـ temporal stabilization.
- Combined A+B.
- Ablation study كامل.
- Final video مدته 4.08 ثانية.
- Bonus neural TTS module مع multi-voice و emotion/style controls.

أفضل نتيجة كانت Enhancement B لأنها حققت أعلى توازن بين جودة الفيديو، الثبات الزمني، semantic alignment، ومدة الفيديو المطلوبة.

26. Checklist للتسليم

قبل التسليم، لازم يكون معاك:

- النوتبوك بالـ outputs.
- `phase2_ablation_table.csv`
- `phase2_ablation_metrics.png`
- فيديو Enhancement B النهائي.
- `final_video_with_neural_tts.mp4` للبونس.
- zip فيه كل voice/style videos.
- الورقة العلمية وفيها Phase 2 section.
- `requirements.txt`
- `generate_phase2_video.py`
- README لو مطلوب.

27. جملة قصيرة تصلح في العرض

In Phase 2, we improved the Phase 1 SDXL+SVD baseline by adding semantic prompt conditioning and temporal stabilization. The temporal enhancement achieved the best results, increasing SSIM from 0.7049 to 0.9567 and reducing frame difference from 19.9993 to 4.4957. We also added a neural SpeechT5 text-to-audio bonus with multiple voices, emotion/style controls, and synchronized narration with the final video.